Humanités numériques : introduction à l'édition de textes et d'instruments de recherche (XML)

E. ROUQUETTE

Cours 3 - 5 décembre 2023



Exemple d'éditions en XML-TEI

```
Liste des projets utilisant la TEI:
https://tei-c.org/activities/projects/

Quelques exemples:

Édition des capitulaires carolingiens: https:
//capitularia.uni-koeln.de/en/mss/paris-bn-lat-2718/
Base de Français Médiéval
https://txm-bfm.huma-num.fr/txm/
Les manuscrits de Stendhal http://stendhal.demarre-shs.fr/
```

Utiliser la TEI

Pour utiliser un set de balises TEI, il faut déclarer **l'espace de nom TEI** (namespace) dans l'élément racine grâce à une **adresse URI**

```
<TEI xmlns="http://www.tei-c.org/ns/1.0">
```

Le logiciel oXygen le fait automatiquement lorsque l'on créé un document TEI : Nouveau - modèle du framework - TEI P5 - All

Petit détour par les espaces de noms (namespace)

Définitions

Espace de nom (namespace) Un espace de nom indique le vocabulaire XML dont sont issus les éléments et attributs utilisés dans un document XML.

URI Uniform Resource Identifier. Identifiant qui permet de désigner sans ambiguïté un document externe (ou plus généralement une ressource), par exemple des DTD.

Ressource sur les espaces de noms : https://www.irif.fr/~carton/ Enseignement/XML/Cours/support.html#chap.namespace

Petit détour par les espaces de noms (namespace)

- Un espace de noms est identifié par un URI, qui est la plupart du temps également une URL, permettant d'accéder à la documentation de l'espace de noms.
- Combiner les espaces de noms permet de ne pas avoir à redéfinir des balises déjà définies dans d'autres vocabulaires/langages XML
- On peut choisir un espace de nom par défaut et attribuer aux autres espaces de noms un préfixe servant à identifier leurs balises
- On peut appeler des espaces de nom seulement au niveau des éléments concernés ou de leur élément parent

Petit détour par les espaces de noms (namespace)

Appeler plusieurs espaces de noms :

```
<elementRacine
xmlns="namespaceDesÉlémentsNonPréfixés"
xmlns:prefixe1="namespace1"
xmlns:prefixe2="namespace2" ...>
```

Exemple

- 1. Nous pourrons utiliser les éléments définis par la TEI sans les préfixer
- 2. Nous pourrons utiliser les éléments du vocabulaire MathML, en les préfixant avec mml : Exemple : <mml:math>.
- 3. Nous pourrons utiliser les éléments du vocabulaire défini par le W3C, en les préfixant avec xml : Exemple : <xml:id>.

Exercice 1 : créer avec oXygen un document XML-TEI

Nouveau - modèle du framework - TEI P5 - All

Encoder de la façon suivante le premier vers de l'acte IV du *Cid* de Corneille, **en observant quelles sont les balises proposées par oXygen** avec la commande Ctl-E :

```
<sp>
  <speaker>Don Diègue</speaker>
  <1>Û rage! ô désespoir! ô vieillesse ennemie!</1>
</sp>
```

Exercice 1 : créer avec oXygen un document XML-TEI

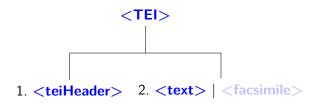
Nouveau - modèle du framework - TEI P5 - All

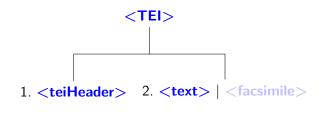
Encoder de la façon suivante le premier vers de l'acte IV du *Cid* de Corneille, **en observant quelles sont les balises proposées par oXygen** avec la commande Ctl-E :

```
<sp>
  <speaker>Don Diègue</speaker>
  <1>Û rage! ô désespoir! ô vieillesse ennemie!</1>
  </sp>
```

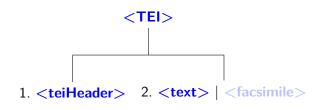
ightarrow La balise <speaker> n'est pas proposée si l'on n'est pas dans un élément <sp>

Les éléments obligatoires d'un document TEI

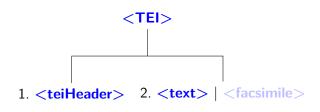




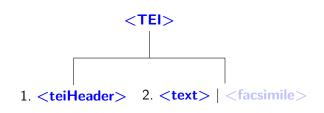
<TEI> l'élement racine



<TEI> l'élement racine <teiHeader> l'élément contenant les métadonnées



<TEI> l'élement racine
<teiHeader> l'élément contenant les métadonnées
<text> le texte encodé

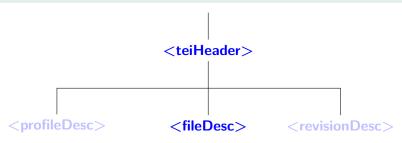


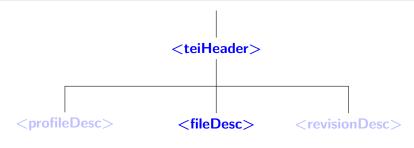
<TEI> l'élement racine

<teiHeader> l'élément contenant les métadonnées

<text> le texte encodé

<facsimile> élément pouvant remplacer l'élément <text> pour des éditions en fac-similé (images plutôt que texte)

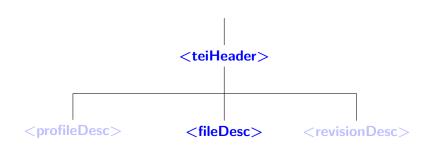




```
<teiHeader>
cprofileDesc> <fileDesc> <revisionDesc>
```

```
<teiHeader>
cprofileDesc> <fileDesc> <revisionDesc>
```

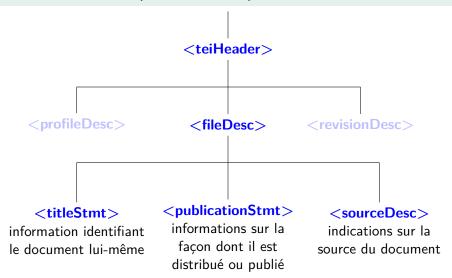
- <fileDesc> «File description» : Description bibliographique du
 fichier électronique (obligatoire)
- - ... (d'autres éléments existent)

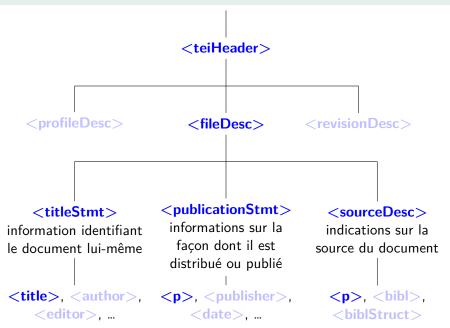


Convention de nommage

```
_Stmt «statement» : contenu structuré en sous-éléments
```

_Desc « description » : description en prose, pouvant admettre des sous-éléments





Les modules du teiHeader

Le teiHeader peut être étendu par différents modules optionnels en fonction de la nature du texte encodé :

- msdescription pour les manuscrits
- textcrit pour l'édition critique
- etc...

Les métadonnées : exemples

```
<teiHeader>
 <fileDesc>
  <titleStmt>
   <title>Le document TEI minimal</title>
  </titleStmt>
  <publicationStmt>
   Distribué comme partie de TEI P5
  </publicationStmt>
  <sourceDesc>
   Aucune source : ce document est né

→ numérique
  </sourceDesc>
 </fileDesc>
</teiHeader>
   (source: TEI Guidelines, The TEI Header and Its Components)
```

Les métadonnées : exemples

```
<teiHeader>
 <fileDesc>
  <titleStmt>
   <title>Thomas Paine: Common sense, a machine-readable

→ transcript</title>

   <respStmt>
    <resp>compiled by</resp>
    <name>Jon K Adams</name>
   </respStmt>
  </titleStmt>
  <publicationStmt>
  <distributor>Oxford Text Archive</distributor>
  </publicationStmt>
  <sourceDesc>
   <bibl>The complete writings of Thomas Paine, collected and

→ edited by Phillip S. Foner (New York, Citadel Press,

→ 1945)</bibl>

  </sourceDesc>
</fileDesc>
</te>
```

(source: TEI Guidelines, The TEI Header and Its Components)

Exercice 2

Encoder de façon simplifiée les métadonnées pour un document TEI dont les références seraient :

- Édition numérique du Capitulaire de Théodulf
- Dans le cadre du cours d'initiation à XML de l'EnC
- D'après l'édition de Peter Brommer (MGH, Capitula episcoporum, I)

Éléments à utiliser au sein des trois éléments obligatoires du <fileDesc> : <title>, <author>, , <bibl>

Solution

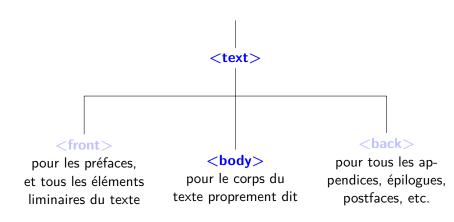
```
<teiHeader>
 <fileDesc>
  <titleStmt>
   <title>Édition numérique du Capitulaire de

→ Théodulf</title>

  </titleStmt>
  <publicationStmt>
   Non publié (cours d'initiation à XML de
\rightarrow 1'EnC)
  </publicationStmt>
  <sourceDesc>
   D'après l'édition de <bibl>Peter Brommer,
                                                 MGH.

→ Capitula episcoporum, I </bibl>
  </sourceDesc>
 </fileDesc>
</teiHeader>
```

Le corps du texte



Le document TEI minimal

```
<TEI xmlns="http://www.tei-c.org/ns/1.0">
<teiHeader>
 <fileDesc>
  <titleStmt>
   <title>Titre du document electronique</title>
  </titleStmt>
  <publicationStmt>
   Informations sur la publication de l'œuvre.
  </publicationStmt>
  <sourceDesc>
   Informations sur la source dont est tirée l'œuvre.
  </sourceDesc>
 </fileDesc>
</teiHeader>
<text>
 <body>
  Le contenu du texte qu'on va encoder
  </body>
 </text>
</TEI>
```



Les divisions du texte

```
<div> Divisions du texte (chapitre, actes, parties, etc). Peut
             être précisé par l'attribut Otype (valeur libre).
<div1>, <div2>, etc : divisions imbriguées
    <head> Titres de section
        paragraphes
        <|> vers
      <|g> « line group » ensemble de vers faisant unité (strophe,
             laisse,...). Peut être précisé par l'attribut Otype
             (valeur libre)
      <ab> « anonymous block » type de séquence textuelle ne
             correspondant pas à ces divisions
```

Les divisions du texte

```
<div> Divisions du texte (chapitre, actes, parties, etc). Peut
             être précisé par l'attribut Otype (valeur libre).
<div1>, <div2>, etc : divisions imbriguées
    <head> Titres de section
        paragraphes
       <|> vers
      <lg> « line group » ensemble de vers faisant unité (strophe,
             laisse,...). Peut être précisé par l'attribut Otype
             (valeur libre)
      <ab> « anonymous block » type de séquence textuelle ne
             correspondant pas à ces divisions
       <s> phrase
      <w> mot
      <pc> ponctuation
       <c> caractère
```

Les noms propres

Deux possibilités :

- 1. <name>, qui peut être précisé avec l'attribut @type (valeurs possibles : "person", "place", ""org"
- <persName>, <placeName>, or <orgName> : nom de personne, nom de lieu, non d'organisation.

La seconde solution est préférée, en particulier quand on veut créer un index.

La balise <persName> peut recevoir l'attribut @type; elle peut avoir des enfants indiquant les composants du nom, par exemple <surname> et <forname>

<rs> : reference string : chaîne de caractères faisant référence à
une entité ou un lieu, même sans contenir de nom propre (par
exemple : l'abbé, lui, etc).

Donner un identifiant à un élément

L'attribut @xml :id

Appartient à l'espace de nom XML

Permet d'attribuer à un élément un identifiant unique auquel il est ensuite possible de se référer dans le cours du document : à des personnes, des lieux, des divisions du texte, des références bibliographiques, etc

L'identifiant peut être attribué entre l'élement <teiHeader> et l'élément <text> , par exemple dans l'élément <standOff>, ou dans le corps du texte.

 ${\bf standOff}$: « Functions as a container element for linked data, contextual information, and stand-off annotations embedded in a TEI document. »

Donner un identifiant à un élément

```
Exemple:
<TET>
<teiHeader>
</teiHeader>
<standOff>
  <listPerson>
   <person>
   <persName xml:id="Dest">Charles-Louis-Joseph Destale/persName>
   </person>
  </listPerson>
 </standOff>
<text>
  <body>
   <rs ref="#Dest">L'abbé</rs> est en manchettes de dentelles
  </body>
 </text>
</TEI>
```

Donner un identifiant à un élément

```
Exemple:
<bibl xml:id="tlk_36">Tolkien (1936)</bibl> tells us
\hookrightarrow that
<quote source="#tlk_36">
<title>Beowulf</title> is in fact so interesting as
   poetry, in places poetry so powerful, that this
    quite overshadows the historical content
</quote>.
(exemple tiré des Guidelines)
```

Exercice 3: encoder en TEI

Encoder de façon simple le début du livre I des *Essais* de Montaigne, édition de 1907, en utilisant l'attribut @xml :id pour les noms propres et les divisions du texte qui vous semblent pertinentes (ne vous préoccupez pas des métadonnées ici)

Le texte à encoder se trouve dans le fichier transcription_Montaigne.txt

Source: https://fr.wikisource.org/wiki/Essais/%C3% A9dition_Michaud,_1907/Livre_I/Chapitre_1

Exercice 3: encoder en TEI

Encoder de façon simple le début du livre I des *Essais* de Montaigne, édition de 1907, en utilisant l'attribut @xml :id pour les noms propres et les divisions du texte qui vous semblent pertinentes (ne vous préoccupez pas des métadonnées ici)

Éléments à utiliser au sein de <body> :

- ► <div1>, <div2>
- ►
- <head>
- <persName>
- <placeName>



La TEI : un cadre modulaire

- La TEI n'est pas un schéma
- La TEI fournit un cadre pour créer son propre schéma
- ► Les *Guidelines* de la TEI sont un guide pour se repérer dans la grammaire TEI
- ► Elles définissent plusieurs centaines de concepts différents, avec les instructions détaillées sur les éléments et les attributs qui peuvent être utilisés pour les représenter et la façon dont ils peuvent être combinés.
- Les concepts sont regroupés en **modules**

http://www.tei-c.org/ Guideline

Les modules sont des ensembles cohérents de balises. Il y a 23 modules

Les modules sont des ensembles cohérents de balises. Il y a 23 modules

▶ 4 modules obligatoires : → métadonnées et éléments les plus courants

Les modules sont des ensembles cohérents de balises. Il y a 23 modules

- ▶ 4 modules obligatoires : → métadonnées et éléments les plus courants
- ▶ 18 modules additionnels selon le type de texte encodé (poésie, théâtre, dictionnaire, ...) ou le type de données (apparat critique, élément graphique, ...)

Les modules sont des ensembles cohérents de balises. Il y a 23 modules

- ▶ 4 modules obligatoires : → métadonnées et éléments les plus courants
- ▶ 18 modules additionnels selon le type de texte encodé (poésie, théâtre, dictionnaire, ...) ou le type de données (apparat critique, élément graphique, ...)

On peut combiner les éléments de différents modules pour composer son propre schéma (\rightarrow cours 4)



TEI Guidelines PS varion 4.7.0 Last updated on 16th November 2023, revision end/17045. This page generated on 2023-21-16720.03.552

Table des matières des Guidelines. Chaque chapitre couvre un module.

Text Body

- 1 The TEI Infrastructure
- 2 The TEI Header
- 3 Elements Available in All TEI Documents
- 4 Default Text Structure
- 5 Characters, Glyphs, and Writing Modes
- 6 Verse
- 7 Performance Texts
- 8 Transcriptions of Speech
- 9 Dictionaries

- 13 Names, Dates, People, and Places
- 14 Tables, Formulæ, Graphics, and Notated Music

- 19 Graphs, Networks, and Trees

- ± 23 Using the TEI

Module name	Formal public identifier	Where defined
analysis	Analysis and Interpretation	17 Simple Analytic Mechanisms
certainty	Certainty and Uncertainty	21 Certainty, Precision, and Responsibility
core	Common Core	3 Elements Available in All TEI Documents
corpus	Metadata for Language Corpora	15 Language Corpora
dictionaries	Print Dictionaries	9 Dictionaries
drama	Performance Texts	7 Performance Texts
figures	Tables, Formulae, Figures	14 Tables, Formulæ, Graphics, and Notated Music
gaiji	Character and Glyph Documentation	5 Characters, Glyphs, and Writing Modes
header	Common Metadata	2 The TEI Header
iso-fs	Feature Structures	18 Feature Structures
linking	Linking, Segmentation, and Alignment	t 16 Linking, Segmentation, and Alignment
msdescription	Manuscript Description	10 Manuscript Description
namesdates	Names, Dates, People, and Places	13 Names, Dates, People, and Places
nets	Graphs, Networks, and Trees	19 Graphs, Networks, and Trees
spoken	Transcribed Speech	8 Transcriptions of Speech
tagdocs	Documentation Elements	22 Documentation Elements
tei	TEI Infrastructure	1 The TEI Infrastructure
textcrit	Text Criticism	12 Critical Apparatus
textstructure	Default Text Structure	4 Default Text Structure
transcr	Transcription of Primary Sources	11 Representation of Primary Sources
verse	Verse	6 Verse

le nom des modules (présenté dans le module 1)

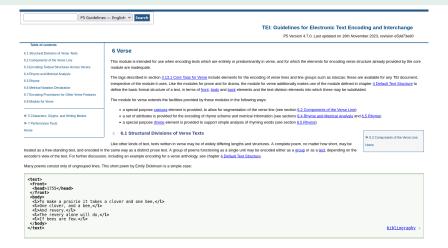
Les modules obligatoires :

- tei définition des classes, macros et types de données
- header en-tête TEI (métadonnées du document)
 - core éléments incontournables pour tout type de document

textstructure éléments de base pour structurer un texte de type livre

Text Body

- 2 The TEI Header
- 3 Elements Available in All TEI Documents
- 4 Default Text Structure



Exemple de description de module : le module verse

Les classes

Les éléments et les attributs sont également organisés en classes de modèle (model class) et classes d'attributs (attribute class)

model.class (Classe de modèle) Regroupe des éléments qui peuvent se trouver au même endroit dans le document + regroupement sémantique att.class (Classe d'attributs) Regroupe des éléments qui partagent les mêmes attributs

Back Matter

- ⊕ Appendix B <u>Attribute Classes</u>
- ⊕ Appendix C <u>Elements</u>
- Appendix D Attributes
- Appendix E <u>Datatypes and Other Macros</u>

- Appendix H Prefatory Notes

Appendix I Colophon

Classes et liste de l'ensemble des éléments définis dans la TEI

Les classes de modèle

Exemple de classes de modèle

- - model.phrase Éléments pouvant apparaître au niveau de la phrase
 - model.nameLike Regroupement sémantique pour les divers types de noms

Les classes de modèle

La liste alphabétique des classes de modèle dans les Guidelines



Les classes de modèle

Exemple : la classe model.quoteLike

model.quoteLike

model.quoteLike groups elements used to directly contain quotations.				
Module	tei — The TEI Infrastructure			
Used by	model.attributable model.msltemPart			
Members	<u>cit quote</u>			

Les classes d'attributs

Exemple de classes d'attributs

```
att.global Attributs pouvant être utilisés avec tout élément.

Contient : @xml :id, @n, @xml :lang, ...
```

att.naming Les attributs communs aux différents éléments qui se réfèrent à des noms de personnes, de lieux, d'organisations, etc. Contient : @key, @ref, @role,

Les classes d'attributs

La liste alphabétique des classes d'attribut dans les Guidelines

att.anchoring att.ascribed att.ascribed.directed
att.breaking
att.calendarSystem att.canonical att.citeStructurePart att.citing att.combinable att.coordinated att.cReferencing
i e e e e e e e e e e e e e e e e e e e
att.damaged_att.datable_att.datable.custom_att.datable.iso_att.datable.w3c_att.datcat_att.declarable_att.declaring_att.deprecated_att.dimensions
att.divLike att.docStatus att.duration att.duration.iso att.duration.w3c
att.edition att.editLike att.enjamb att.entryLike
att.formula att.fragmentable
att.gaijiProp att.global att.global.analytic att.global.change att.global.facs att.global.linking att.global.rendition att.global.responsibility.
at, global, source
1
att.handFeatures
att.identified att.internetMedia att.interpLike
att.lexicographic att.lexicographic.normalized att.linguistic att.locatable
-

Les classes d'attributs

Exemple: la classe d'attribut att.witnessed

att.witnessed				Home B Attribute Classes			
att.witnessed provides attributes used to identify the witnesses supporting a particular reading in a critical apparatus. [12.1 The Apparatus Entry, Readings, and Witnesses]							
Module	textcrit — Critical Apparatus						
Members	lem rdg						
Attributes	@wit ±	(witness or witnesses) contains a space-delimited list of one or more pointers indicating the witnesses which attest to a given reading.					
		Status	Optional				
		Datatype	1∞ occurrences of $\underline{teidata.pointer}$ separated by whitespace				
		Note	If the apparatus contains readings only for a single witness, this attrib ornited. This attribute may occur both within an apparatus gathering variant re transcription of an individual witness and within an apparatus gatherin witnesses. Additional descriptions or alternative versions of the sigla referenced content of a child <u>wit</u> element.	adings in the g readings from different			

Exercice 4 : résoudre un problème d'encodage précis en utilisant les *Guidelines*

Trouver comment encoder une liste de personnages et les indications de lieu au début d'une pièce de théâtre; encoder celles du *Cid*. Le texte à encoder se trouve dans le fichier transcription_Cid.txt (https://fr.wikisource.org/wiki/Le_Cid/%C3%89dition_Ginn/Personnages)

DON FERNAND, premier roi de Castille DONA URRAQUE, infante de Castille DON DIÉGUE, père de don Rodrigue DON GOMÈS, comte de Gormas, père de Chimène DON RODRIGUE, amant de Chimène DON SANCHE, amoureux de Chimène DON ARIA DON ALONSE Gentilshommes castillans. CHIMÈNE, fille de don Gomès LÉONOR, gouvernante de l'Infante ELVIRE, gouvernante de Chimène UN PAGE de l'Infante

Solution

```
<text>
<front>
  <castList>
   <head>ACTEURS</head>
   <castItem>
    <role>DON FERNAND</role>
    <roleDesc>premier roi de Castille</roleDesc>
   </castItem>
   <castItem>
    <role>DONA URRAQUE</role>
    <roleDesc>infante de Castille</roleDesc>
   </castItem>
<!-- et caetera -->
  </castList>
   <set>
    La scène est à Séville
   </set>
</front>
 <body>...</body>
</text>
```

Solution

```
Cas particulier : les rôles regroupés
<castGroup rend="braced">
 <castItem>
  <role>DON ARIA</role>
 </castItem>
 <castItem>
  <role>DON ALONSE</role>
 </castItem>
 <roleDesc>gentilshommes castillans</roleDesc>
</castGroup>
```

Exercice 5

Résoudre un problème précis d'encodage en s'appuyant sur les *Guidelines*

Rechercher dans les *Guidelines* de la TEI des balises et attributs pour remplacer celles que nous avons utilisées dans notre encodage initial du poème «L'Adieu».

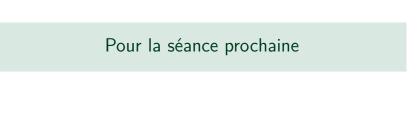
ightarrow transformer l'encodage suivant en encodage valide selon le vocabulaire XML-TEI :

```
<titre>L'Adieu</titre>
  <poeme>
  <vers rime="A" num="1">J'ai cueilli ce brin de bruyère</vers>
  <vers rime="B" num="2">L'automne est morte souviens-t'en </vers>
  <vers rime="A" num="3">Nous ne nous verrons plus sur terre</vers>
  <vers rime="A" num="4">Odeur du temps brin de bruyère </vers>
  <vers rime="B" num="5">Et souviens-toi que je t'attends</vers>
</poeme>
```

Ne vous préoccupez pas des métadonnées (<teiHeader>).

Solution

```
<text>
<front>
<head>L'Adieu</head>
</front>
<body>
<l n="1" rhyme="B">J'ai cueilli ce brin de bruyère</l>
<l n="2" rhyme="B">L'automne est morte souviens-t'en</l>
<l n="3" rhyme="A">Nous ne nous verrons plus sur terre</l>
<l n="4" rhyme="A">Odeur du temps brin de bruyère</l>
<l n="5" rhyme="A">Et souviens-toi que je t'attends</l>
</body>
</text>
```



Lire dans Qu'est-ce que la Text Encoding Initiative de Lou Burnard les deux chapitres sur « la corne d'abondance de la TEI » et le chapitre « Personnaliser la TEI »

Exercice 6 : Résoudre un problème précis d'encodage en s'appuyant sur les *Guidelines*

- ► Encoder les métadonnées, le titre, les épigraphes et les dix premières entrées de lettre A du *Dictionnaire des idées reçues* de Flaubert.
- ► Le texte à transcrire est dans le fichier transcription_Flaubert.txt
- Source du texte :
 https://fr.wikisource.org/wiki/Dictionnaire_des_
 id%C3%A9es_re%C3%A7ues/Texte_entier